

Geração de imagens artificiais e extração de características latentes aplicadas à classificação de imagens

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Pereira Ponti Junior

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

27 de março de 2015



Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann restrita

• Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Motivação

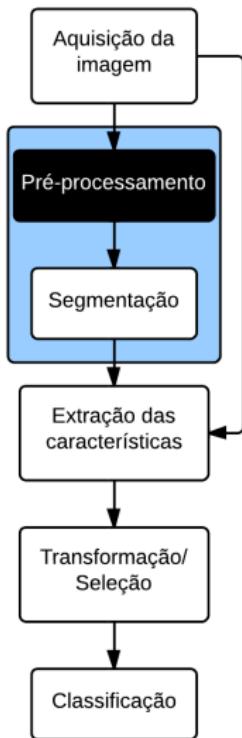


Figura: Etapas canônicas do reconhecimento de padrões.

Motivação

- ▶ Maior esforço ao operar no espaço de características já obtidas;
- ▶ Transformações do espaço ou sistemas complexos de classificação para lidar com as deficiências das características extraídas;
- ▶ Características que podem ser exploradas além dos métodos clássicos;
- ▶ Investigar métodos de processamento e preparação de imagens antes da extração.

Motivação - Características Latentes



(a)



(b)



(c)



(d)



(e)



(f)



(g)



(h)



(i)



(j)



(k)



(l)

Figura: Características latentes de algas verdes.

Motivação - Características Latentes

- ▶ Métodos de processamento e preparação de imagens antes da extração dessas características;
- ▶ Podem revelar características latentes, não visíveis nas imagens originais;
- ▶ Foco: *realçar características que possam melhor descrever certas classes, utilizando algoritmos sobre as imagens originais.*

Motivação

- ▶ (Rocha et al., 2010) 98% de acurácia após aquisição, pré-processamento e segmentação;
- ▶ (Kanan e Cottrell, 2012) Quantização pode impactar a classificação;
- ▶ (Ponti et al., 2014) Quantização permite obter vetores de características mais compactos e com maior capacidade de discriminação entre classes;

Continuação: analisar redes que aprendem quais operações geram essas características.

Motivação - Desbalanceamento de classes

- ▶ Diferença entre o número de exemplos disponíveis;
- ▶ Imagens representam eventos importantes mas menos frequentes;
- ▶ Obstáculo, métodos de transformação do espaço e de classificação assumem que a base está balanceada;
- ▶ Foco: *geração de imagens artificiais a partir do realce de características das imagens da classe minoritária.*



Figura: Imagem artificialmente gerada.

Proposta da Pesquisa

Melhorar a classificação de imagens, utilizando métodos de processamento com foco na **extração de características latentes** e no **rebalanceamento de classes**.

Hipóteses

Métodos de pré-processamento

- ▶ Extrair características latentes que aumentem a variância entre as classes, sem aumentar a variância intra-classe;
- ▶ Melhorar a classificação.

Geração de imagens artificiais

- ▶ Balancear as classes;
- ▶ Melhorar a acurácia, versus geração de exemplos artificiais no espaço de atributos.

Objetivo Geral

Investigar os métodos de pré-processamento para preparar uma coleção de imagens para a extração de características.

Espera-se obter características latentes e balancear o número de instâncias de diferentes classes.

Objetivos Específicos

- ▶ Analisar:
 - ▶ impacto de métodos canônicos na classificação;
 - ▶ aprendizado de bases bem discriminadas por redes de convolução.
- ▶ Tornar as características latentes visíveis;
- ▶ Gerar imagens artificiais a partir das imagens pertencentes às classes minoritárias.
 - ▶ Resultados preliminares;
 - ▶ Matriz de características aprendida por uma máquina de Boltzmann restrita para verificar a relevância das imagens geradas e as imagens originais.

Objetivos Específicos

- ▶ Analisar:
 - ▶ impacto de métodos canônicos na classificação;
 - ▶ aprendizado de bases bem discriminadas por redes de convolução.
- ▶ Tornar as características latentes visíveis;
- ▶ Gerar imagens artificiais a partir das imagens pertencentes às classes minoritárias.
 - ▶ Resultados preliminares;
 - ▶ Matriz de características aprendida por uma máquina de Boltzmann restrita para verificar a relevância das imagens geradas e as imagens originais.

Proposta

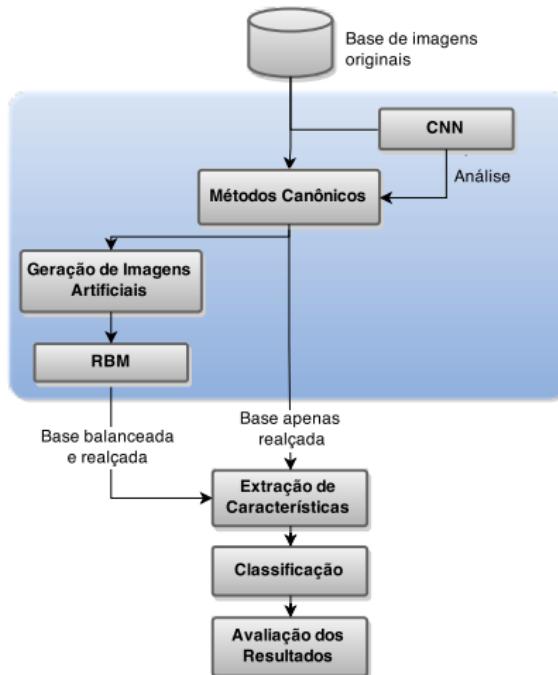


Figura: Estrutura geral desta pesquisa.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-trita

● Extração de características

3 Metodologia

4 Resultados

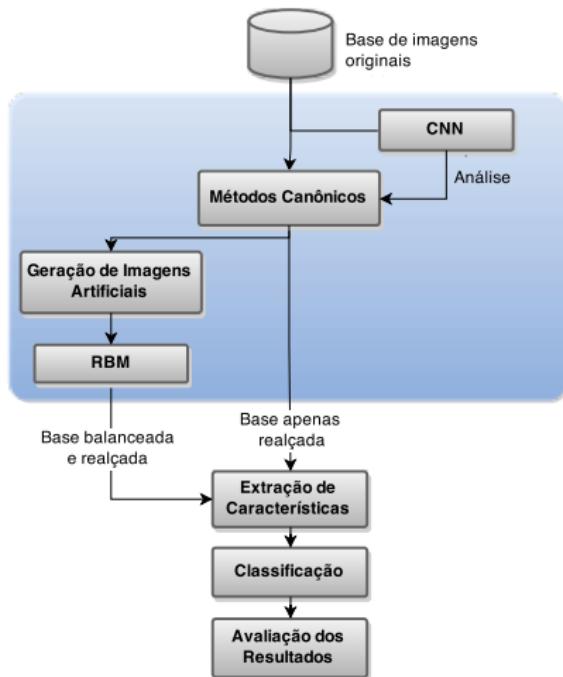
- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Pré-processamento de Imagens



Pré-processamento de Imagens

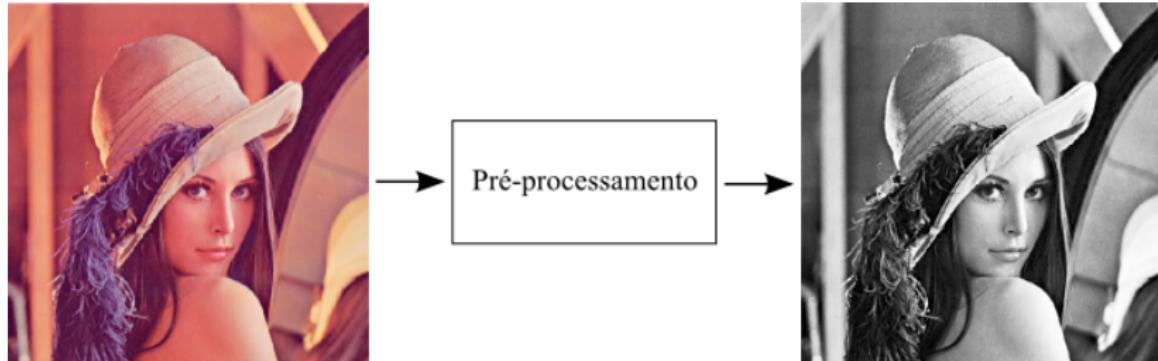


Figura: Borramento, realce e de equalização de histograma.

Pré-processamento de Imagens - Convolução

- ▶ Percorre a imagem com um filtro espacial rotacionado em 180°;
- ▶ Cria cada novo pixel com as mesmas coordenadas do centro da vizinhança contendo o valor resultante da filtragem.

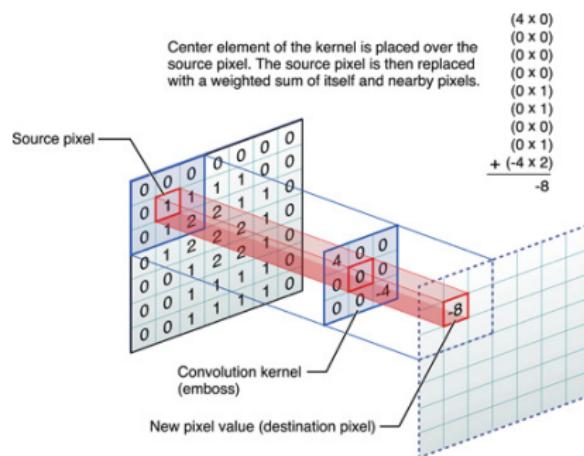
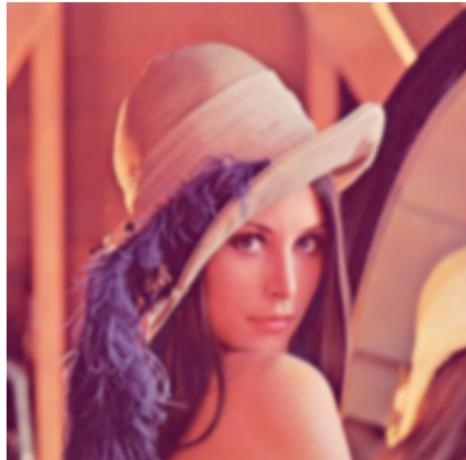


Figura: Convolução com filtro previamente rotacionado.

Pré-processamento de Imagens - Convolução



(a) Original



(b) Filtragem Gaussiana

Pré-processamento de Imagens - Realce

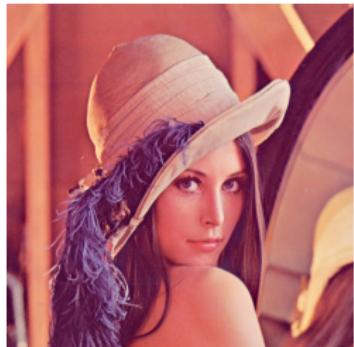


(a) Original

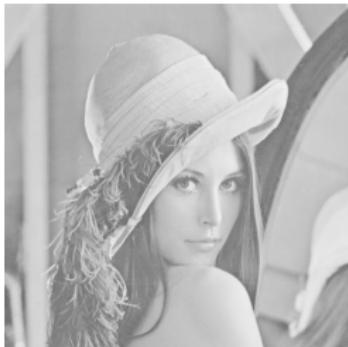


(b) *Unsharp masking*

Pré-processamento de Imagens - Quantização



(a) Original

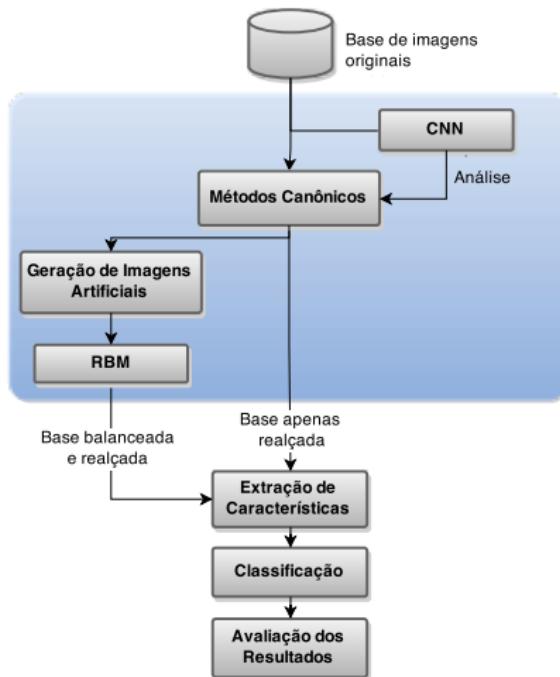


(b) Intensidade



(c) MSB

Redes Neurais



Redes Neurais

- ▶ Estado da arte da classificação, reconhecimento e localização de objetos;
- ▶ Imagens como treinamento para inferir as regras para a classificação;
- ▶ Conhecimento através da experiência: ao tentar uma solução e errar, aprendem e podem tentar novamente;
- ▶ Aprendizado: ajuste dos pesos entre a saída esperada e a produzida.

Deep Learning

- ▶ Reconhecimento humano de novos padrões - capacidade de generalização (hierarquias);
- ▶ Simular o funcionamento do cérebro humano por meio de camadas;
- ▶ Redes neurais profundas possuem uma estrutura de muitas camadas – duas ou mais ocultas;
- ▶ Subdividem em problemas mais simples de serem resolvidos;
- ▶ Apesar de representarem o estado da arte em visão computacional, um bom entendimento das suas propriedades ainda está faltando.

Redes de Convolução

Aprendem versões processadas das imagens de entrada: os filtros aprendidos são os que melhor diferenciam as classes.

- ▶ Multiplicações de um filtro espacial pela imagem de entrada, resultando em um mapa de características ativadas;
- ▶ Vetor de parâmetros capaz de aprender;
- ▶ As características ativadas são diferentes;
- ▶ Camada de convolução = muitas convoluções em paralelo, dado que um filtro é capaz de extrair apenas um tipo de característica.

Redes de Convolução

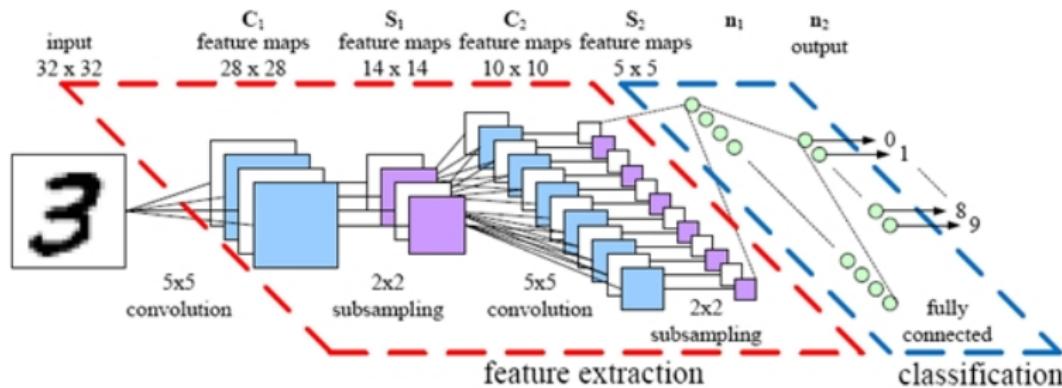


Figura: Arquitetura de uma CNN.

Fonte: <http://parse.ele.tue.nl/education/cluster2>

Redes de Convolução

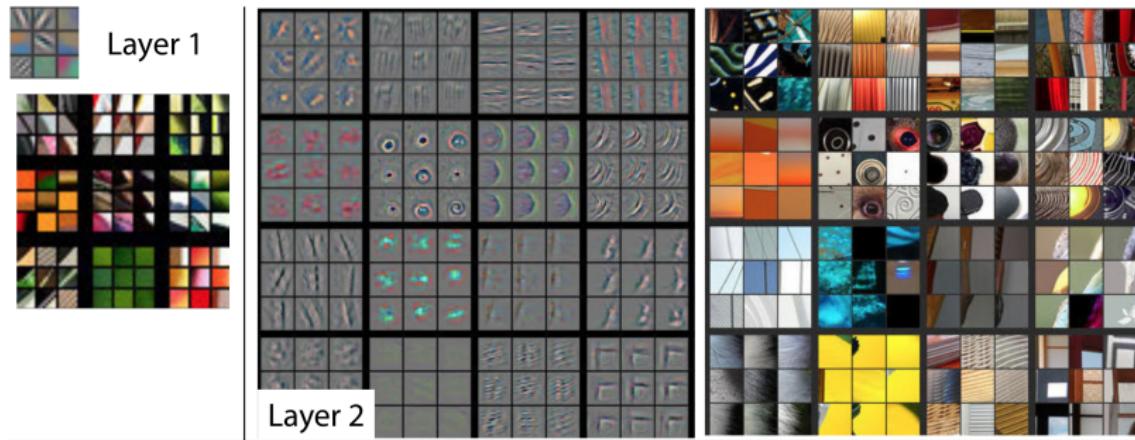


Figura: Primeira e segunda camada.

Fonte: [?]

Redes de Convolução

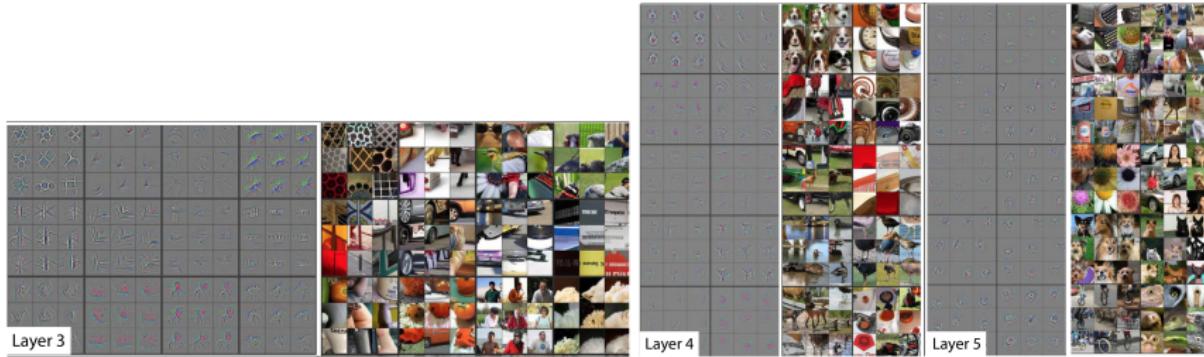
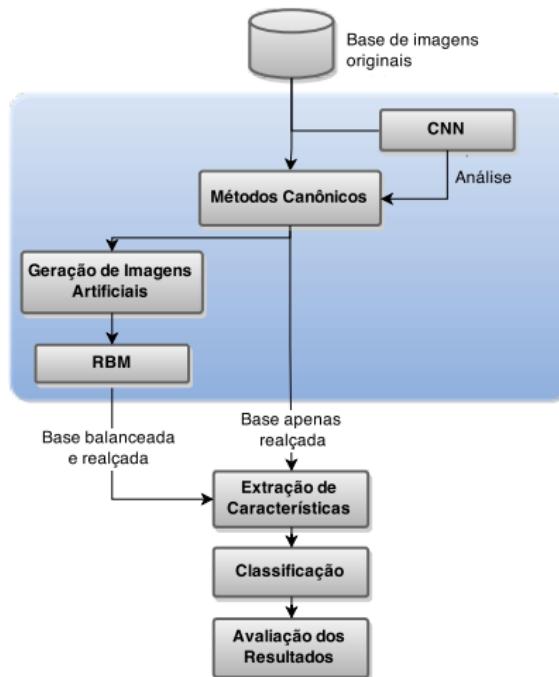


Figura: Terceira, quarta e quinta camada.

Fonte: [?]

Desbalanceamento de classes



Desbalanceamento de classes

- ▶ Número desbalanceado de exemplos. Majoritárias x minoritárias.
- ▶ Abordagens
 - ▶ Pré-processamento dos dados: reamostrar os dados;
 - ▶ Modificar métodos de aprendizagem: adicionar funções de custo na classificação.

Desbalanceamento de classes - Subamostragem

- ▶ Diminuir o número de elementos do conjunto;
- ▶ Podem remover informações essenciais dos dados originais;
- ▶ Eliminar elementos da classe majoritária distantes da fronteira de decisão;
- ▶ Normalmente apresentam resultados piores.

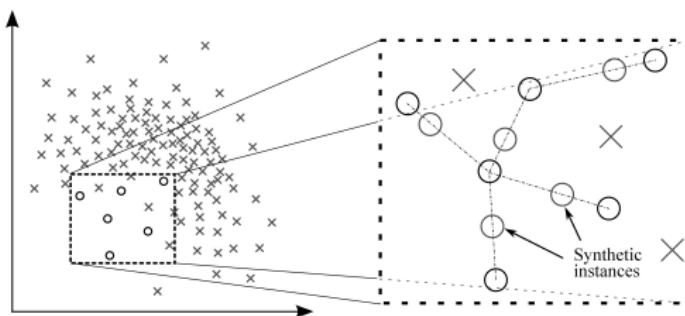
Desbalanceamento de classes - Sobreamostragem

- ▶ Aumentar o número de elementos;
- ▶ Replicar não reporta melhorias;

SMOTE

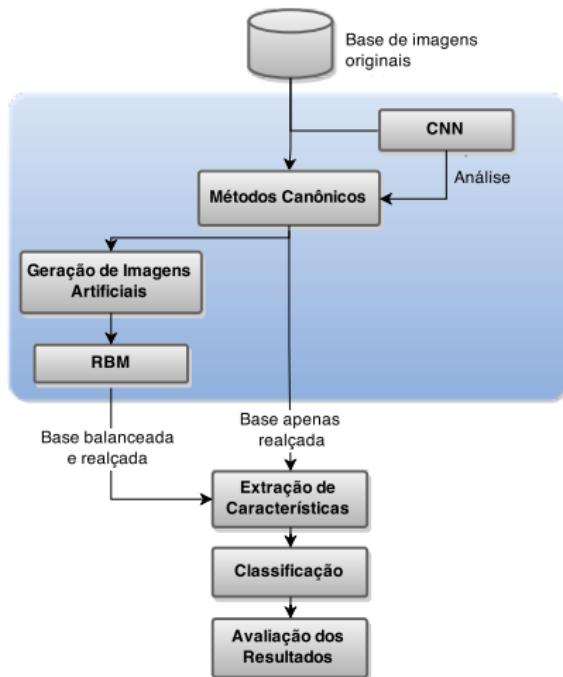
- ▶ Multiplica a diferença entre o vetor de características de um elemento e do seu vizinho mais próximo por um número [0-1];
- ▶ Adiciona ao vetor original, criando um novo elemento entre os dois vetores originais;
- ▶ Aprendida como exemplo da classe minoritária;
- ▶ Força uma região de decisão maior e mais geral;

Desbalanceamento de classes - SMOTE



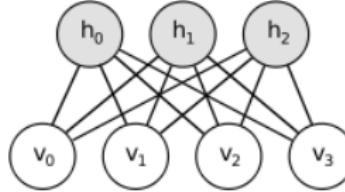
- ▶ Rebalancear ao gerar novos elementos, ao invés de replicá-los;
- ▶ Sobre os vetores de características previamente extraídos;
- ▶ (Chawla et al., 2002) **Diferentes estratégias para criar exemplos sintéticos podem melhorar a performance da classificação;**
- ▶ Utilizado para comparação.

Máquina de Boltzmann restrita



Máquina de Boltzmann restrita

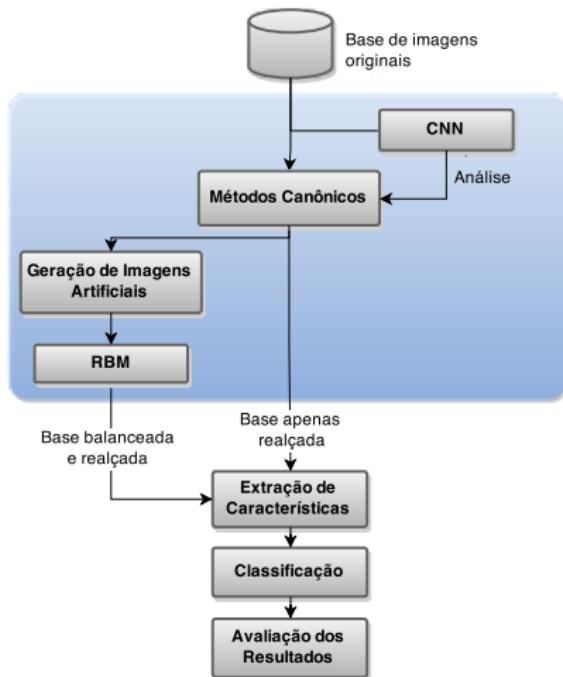
- ▶ Pixels: unidades visíveis. Camada oculta: correlação entre os pixels;
- ▶ Aprendem representações das imagens;
- ▶ Verificação da relevância de uma imagem para o aprendizado;
- ▶ Utilizar apenas um neurônio oculto, com a matriz de pesos como memória associativa.
- ▶ Informação em uma imagem artificialmente gerada.



Redes Neurais

- ▶ Redes neurais de convolução (CNN)
 - ▶ Compreendem todo o pipeline com camadas de neurônios;
 - ▶ Aprendem as melhores características que diferenciam as classes, utilizando convolução;
- ▶ Máquinas de Boltzmann restritas (RBM)
 - ▶ Aprende a representação das imagens de entrada;
 - ▶ Definir quais imagens são relevantes para o aprendizado.

Extração de Características



Extração de Características

- ▶ Descrever as informações visuais relevantes em um vetor de características;
- ▶ Entrada para o classificador de padrões;
- ▶ Salientar as diferenças entre imagens de classes distintas e suavizar possíveis diferenças de imagens da mesma classe (Ex. algas - forma).

Textura: suavidade, aspereza e uniformidade. Ex. entropia;

Forma: características externas. Ex. curvatura;

Cor: distribuição espacial de cores na imagem. Ex. histograma.

Extração de Características

GCH *Histograma global de cor - ND (intensidades).*

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-
trita

- Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Metodologia - Pesquisa Bibliográfica

- ▶ Características latentes;
- ▶ Redes neurais CNN e RBM;
- ▶ Desbalanceamento de classes;
- ▶ Descritores de características;
- ▶ Classificador de padrões.

Metodologia - Implementação

- ▶ Biblioteca OpenCV;
- ▶ Linguagens de programação C++ e Python;
- ▶ Código disponível em [https://bitbucket.org/moacirponti/
imagefeatureextraction/overview](https://bitbucket.org/moacirponti/imagefeatureextraction/overview).

Metodologia - Bases de Imagens

- ▶ Viés genérico: diversas coleções de imagens com o objetivo de estabelecer ou refutar as hipóteses levantadas;
- ▶ Resultados preliminares com a base de imagens COREL^a;

^aDisponível em <http://wang.ist.psu.edu/docs/related/>



Figura: Base de imagens COREL-1000

Metodologia - Bases de Imagens

Bem discriminadas

- ▶ Cor: COREL-1000;
- ▶ Textura: Describable Textures Dataset^a (DTD);
- ▶ Forma: Leafsnap^b;

^a<http://www.robots.ox.ac.uk/~vgg/data/dtd/>

^b<http://leafsnap.com/dataset/>



Figura: DTD.



Figura: Leafsnap.

Metodologia - Experimentos

- ▶ Explorar algoritmos de realce de características relevantes:
 - ▶ Melhorar discriminação entre as classes;
 - ▶ Cenários desbalanceados.
- ▶ Entrada: imagens originais das coleções disponíveis na literatura;
- ▶ Resultado: medidas estatísticas da classificação.

Metodologia - Análise dos dados

- ▶ Comparar a classificação das imagens originais e as tratadas pelo método proposto;
- ▶ Comparar o método de rebalanceamento de classes com técnicas disponíveis na literatura, como o SMOTE.

Metodologia - Avaliação

Medida F1

Problema da acurácia: minoritária sem resultados corretos.

Performance da classificação em cenários desbalanceados.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{PR}{P + R}$$

Metodologia - Avaliação

Medida F1

Problema da acurácia: minoritária sem resultados corretos.

Performance da classificação em cenários desbalanceados.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{PR}{P + R}$$

Metodologia - Avaliação

Friedman

- ▶ Determinar se há diferença significante em uma amostra de resultados gerados;
- ▶ Analisa as performances dos algoritmos e atribui um *rank*;
- ▶ A hipótese nula a ser testada é que não há diferença estatística relevante entre as observações;
- ▶ P-valor indica a significância: quanto menor o seu valor, maior a evidência contra a hipótese nula (limiar de 0,05).

Metodologia - Avaliação

Mahalanobis

Distância entre a média e a variância das classes. Baseia na correlação entre as variáveis e pode ser definida por

$$D_m(x_i) = \sqrt{(x_i - \mu) C^{-1} (x_i - \mu)^T},$$

onde x_i é um vetor de valores, μ a média e C a matriz de covariância.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-
trita

- Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Resultados Esperados

- ▶ Melhorar a classificação, validando-a com a medida-F1.
 - ▶ *Pré-processamento* de imagens que caracterizem melhor aspectos de suas classes, aumentando a variância entre as classes quando comparado com as imagens originais.
 - ▶ *Geração artificial de imagens* de classes minoritárias de forma a compensar o desbalanceamento natural das bases de dados.
- ▶ Analisar as características aprendidas com o treinamento de uma CNN com bases específicas;
- ▶ Escolher imagens que adicionam informações (RBM);
- ▶ Testar bases naturalmente não balanceadas.

Descrição do Experimento



Figura: Geração de imagens artificiais para o rebalanceamento de classes por meio de: borramento, adição de ruído, mistura e combinação.

Descrição do Experimento

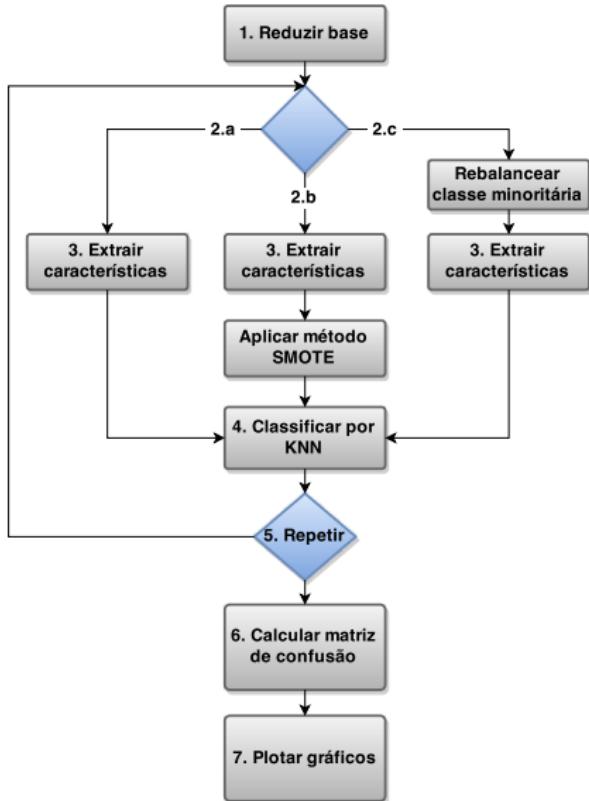


Figura: Fluxo dos resultados preliminares.

Descrição do Experimento

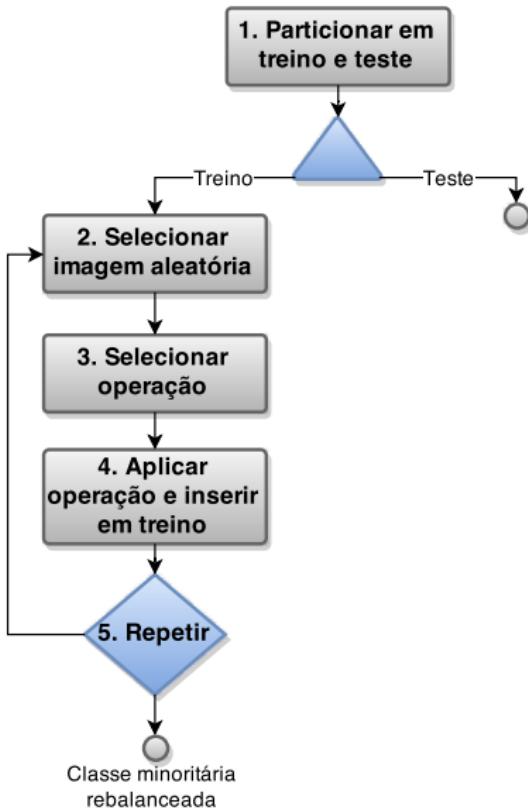


Figura: Fluxo da geração artificial.

Resultados Preliminares

Classes com maior dificuldade de diferenciação, havendo alta taxa de sobreposição de intensidades de cores e texturas.



Figura: Classes “praia” e “montanha” da base de imagens COREL-1000.

Resultados Preliminares - Melhor

- ▶ Ganho estatístico da medida-F, quando comparado à geração de exemplos artificiais no espaço de atributos;

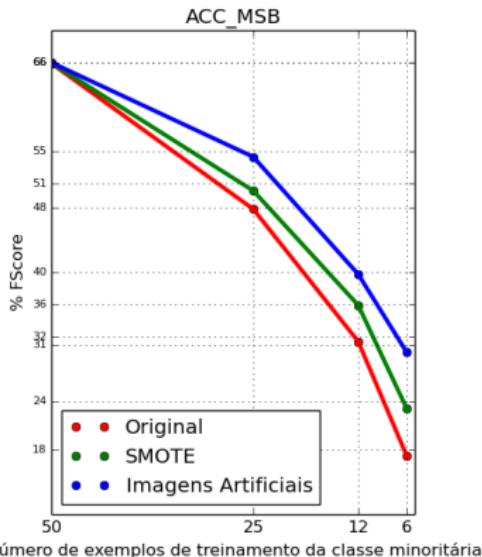


Figura: Resultado obtido com a operação de combinação.

Resultados Preliminares - Pior

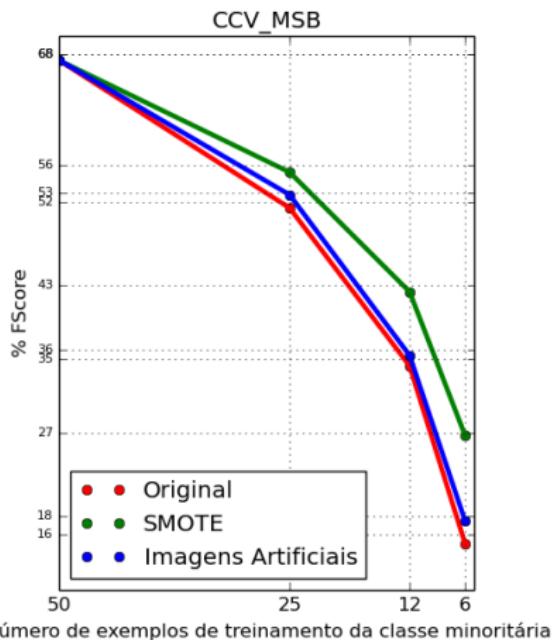


Figura: Piores resultados, obtidos com a adição de ruído.

Resultados Preliminares

- ▶ Melhores operações: todas, apenas mistura e apenas composição;
- ▶ Piores: apenas borramento, ruído ou *unsharp masking* (filtros comuns);
- ▶ Melhor descritor: ACC;
- ▶ Piores: CCV e GCH;

Resultados Preliminares

- ▶ Teste de Friedman para todas as execuções das melhores operações;
- ▶ P-valor = $4.24E^{-11}$; Hipótese nula rejeitada.

Tabela: Posição média dos algoritmos utilizando Friedman

Algoritmos	Posição
Artificial	1.3863
Smote	1.6136
Original	3.0000

- ▶ Em algumas execuções: geração artificial (1), SMOTE (2) e imagens originais (3).

Resultados Preliminares

- ▶ Replicação: SRS - *Simple Random Sampling*;
- ▶ Não adiciona informações novas para o aprendizado.

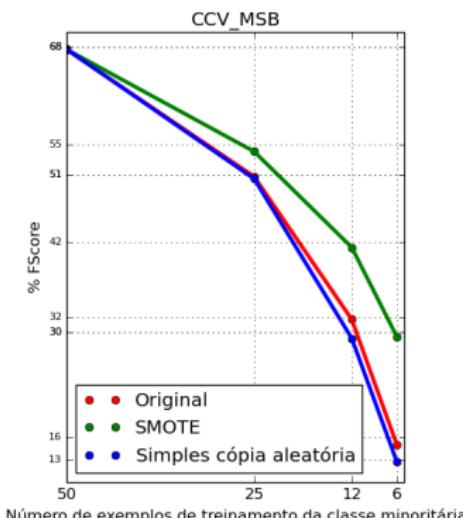


Figura: Simples replicação de exemplos sem pré-processamento.

Resultados Preliminares - Rede de Convolução

<http://caffe.berkeleyvision.org/>

Tabela: Treinamento das classes praia e montanha da base COREL-1000.

Algoritmos	Medida F1
Original	0.708
Desbalanceada	0.577
Rebalanceada	0.677

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-
trita

● Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

- ## 6 Atividades e cronograma
- ## 7 Referências

Próximos Passos

- ▶ Desbalancear as 10 classes da COREL-1000 em escada;
- ▶ Utilizar todas as classes com apenas 1 desbalanceada;
- ▶ Analisar as características latentes que as redes neurais de convolução conseguem extrair
 - ▶ Bases bem discriminadas quanto às propriedades de textura, cor e forma.

Próximos Passos

- ▶ Analisar a memória associativa de uma rede de Boltzmann
 - ▶ As imagens geradas foram adicionadas no conjunto de treino sem verificação da sua relevância;
 - ▶ Escolha para qual imagem original utilizar, ao invés do método aleatório utilizado nos resultados preliminares.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-
trita

● Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Atividades e Cronograma

Tabela: Duração de cada atividade a partir de 24/02/2014.

Atividade	2014		2015		2016
	1º Sem.	2º Sem.	1º Sem.	2º Sem.	1º Sem.
Disciplinas	[REDACTED]	[REDACTED]			
Revisão		[REDACTED]	[REDACTED]		
Geração artificial		[REDACTED]	[REDACTED]	[REDACTED]	
Características latentes			[REDACTED]	[REDACTED]	
Experimentos		[REDACTED]	[REDACTED]	[REDACTED]	
Escrita científica		[REDACTED]	[REDACTED]	[REDACTED]	[REDACTED]

Artigo aceito na Neurocomputing

Image quantization as a dimensionality reduction procedure in color and texture feature extraction

Monair Ponti, Tiago S. Nazaré, Gabriela S. Thumé

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

São Carlos, SP — Brazil — 13566-590

Abstract

The image-based visual recognition pipeline includes a step that converts color images into images with a single channel, obtaining a color-quantized image that can be processed by feature extraction methods. In this paper we explore this step in order to produce compact features that can be used in retrieval and classification systems. We show that different quantization methods produce very different results in terms of accuracy. While compared with more complex methods, this procedure allows the feature extraction in order to achieve a significant dimensionality reduction, while preserving or improving system accuracy. The results indicate that quantization simplify images before feature extraction and dimensionality reduction, producing more compact vectors and reducing system complexity.

Keywords: Image quantization, LPP, compact features extraction

Email addresses: ponti@usp.br (Monair Ponti), tiagoss@usp.br (Tiago S. Nazaré), gabithume@usp.br (Gabriela S. Thumé)

Agradecimentos

Moacir Pereira Ponti Junior



*Conselho Nacional de Desenvolvimento
Científico e Tecnológico*



Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Redes de Convolução
- Desbalanceamento de classes
- Máquina de Boltzmann res-
trita

● Extração de características

3 Metodologia

4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

5 Próximos Passos

6 Atividades e cronograma

7 Referências

Referências

Geração de imagens artificiais e extração de características latentes aplicadas à classificação de imagens

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Pereira Ponti Junior

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

27 de março de 2015

