

# Geração de imagens artificiais e extração de características latentes aplicadas à classificação de imagens

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Pereira Ponti Junior

Instituto de Ciências Matemáticas e de Computação  
Universidade de São Paulo

27 de março de 2015



# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann restrita

- Desbalanceamento de classes

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina;
- ▶ Generalização para classificar novos exemplos;
- ▶ Conjuntos de características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

# Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina;
- ▶ Generalização para classificar novos exemplos;
- ▶ Conjuntos de características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

# Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina;
- ▶ Generalização para classificar novos exemplos;
- ▶ Conjuntos de características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

# Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina;
- ▶ Generalização para classificar novos exemplos;
- ▶ Conjuntos de características que dificultam a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

# Motivação

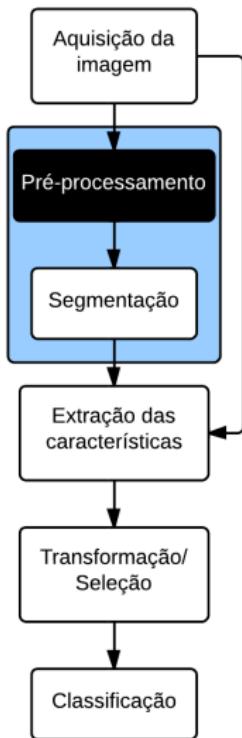


Figura: Etapas canônicas do reconhecimento de padrões.

# Motivação

- ▶ Maior esforço ao operar no espaço de características já obtidas;
- ▶ Transformações do espaço ou sistemas complexos de classificação para lidar com as deficiências das características extraídas;
- ▶ Características que podem ser exploradas além dos métodos clássicos;
- ▶ Investigar métodos de processamento e preparação de imagens antes da extração.

# Motivação - Características Latentes



(a)



(b)



(c)



(d)



(e)



(f)



(g)



(h)



(i)



(j)



(k)



(l)

Figura: Características latentes de algas verdes.

# Motivação - Características Latentes

- ▶ Métodos de processamento e preparação de imagens antes da extração dessas características;
- ▶ Podem revelar características latentes, não visíveis nas imagens originais;
- ▶ O enfoque em realçar determinadas características que possam melhor descrever certas classes, utilizando diversos algoritmos sobre as imagens originais.

# Motivação

- ▶ (Rocha et al., 2010) 98% de acurácia após aquisição, pré-processamento e segmentação;
- ▶ (Kanan e Cottrell, 2012) Quantização pode impactar a classificação;
- ▶ (Ponti et al., 2014) Quantização permite obter vetores de características mais compactos e com maior capacidade de discriminação entre classes;

Continuidade: analisar redes que aprendem quais operações geram as características.

# Motivação - Desbalanceamento de classes

- ▶ Diferença entre o número de exemplos disponíveis;
- ▶ Imagens representam eventos importantes mas menos frequentes;
- ▶ Obstáculo;
- ▶ Métodos de transformação do espaço de características e de classificação assumem que as classes da base estão平衡eadas;
- ▶ Proposta: geração de imagens artificiais.

# Proposta da Pesquisa

Melhorar a classificação de imagens, utilizando métodos de processamento com foco na **extração de características latentes** e no **rebalanceamento de classes**.

# Hipóteses

## Métodos de pré-processamento

- ▶ Extrair características latentes que aumentem a variância entre as classes, sem aumentar a variância intra-classe;
- ▶ Melhorar a classificação.

## Geração de imagens artificiais

- ▶ Balancear as classes;
- ▶ Melhorar a acurácia de algoritmos de classificação, versus geração de exemplos artificiais no espaço de atributos

# Objetivo Geral

*Investigar os métodos de pré-processamento para preparar uma coleção de imagens para a extração de características.*

Espera-se obter características latentes e balancear o número de instâncias de diferentes classes.

# Objetivos Específicos

- ▶ Analisar:
  - ▶ impacto de métodos canônicos na classificação;
  - ▶ aprendizado de bases bem discriminadas por CNN.
- ▶ Tornar as características latentes visíveis. Aumentar a variância entre as classes;
- ▶ Gerar imagens artificiais a partir das imagens pertencentes às classes minoritárias, compensando o desbalanceamento.
  - ▶ Resultados preliminares
  - ▶ Estudo das características latentes encontradas no treinamento da classe minoritária em uma CNN.
  - ▶ Matriz de características aprendida por RBM para verificar a relevância das imagens geradas e as imagens originais.

# Objetivos Específicos

- ▶ Analisar:
  - ▶ impacto de métodos canônicos na classificação;
  - ▶ aprendizado de bases bem discriminadas por CNN.
- ▶ Tornar as características latentes visíveis. Aumentar a variância entre as classes;
- ▶ Gerar imagens artificiais a partir das imagens pertencentes às classes minoritárias, compensando o desbalanceamento.
  - ▶ Resultados preliminares
  - ▶ Estudo das características latentes encontradas no treinamento da classe minoritária em uma CNN.
  - ▶ Matriz de características aprendida por RBM para verificar a relevância das imagens geradas e as imagens originais.

# Proposta

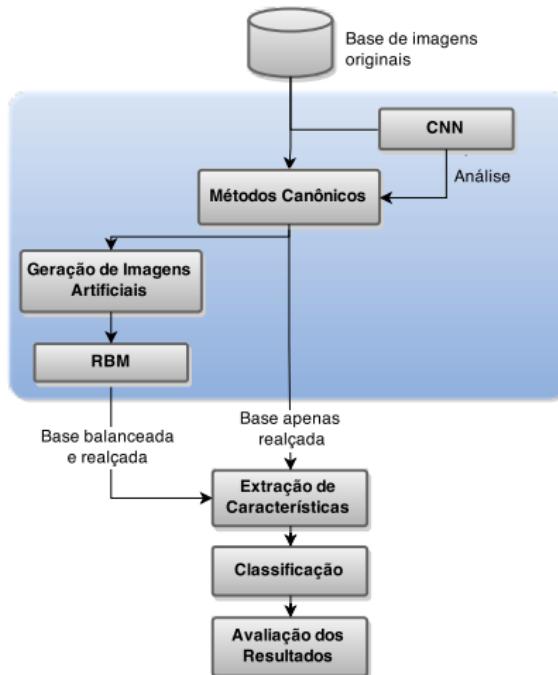


Figura: Estrutura geral desta pesquisa.

# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

## ● Desbalanceamento de clas- ses

## 3 Metodologia

## 4 Resultados

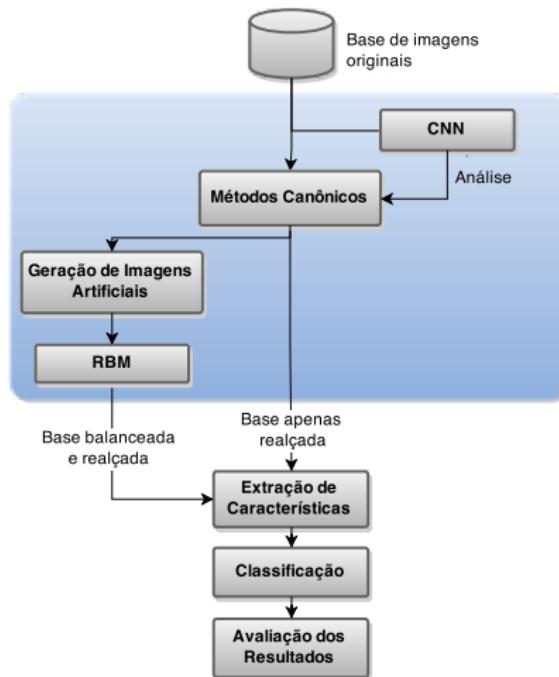
- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Pré-processamento de Imagens



# Pré-processamento de Imagens

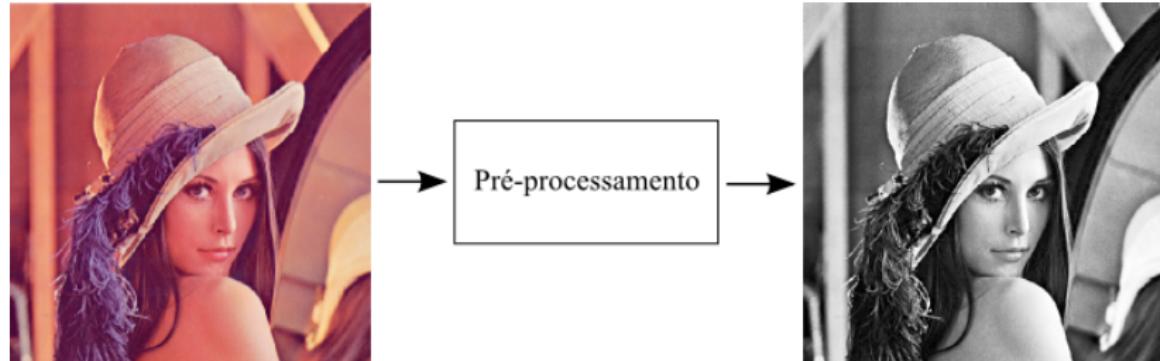


Figura: Borramento, realce e de equalização de histograma.

# Pré-processamento de Imagens - Convolução

- ▶ Percorre a imagem com um filtro espacial rotacionado em 180°;
- ▶ Cria cada novo pixel com as mesmas coordenadas do centro da vizinhança contendo o valor resultante da filtragem.

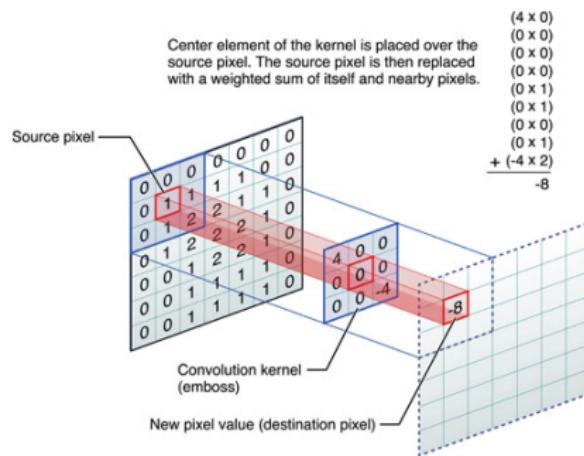
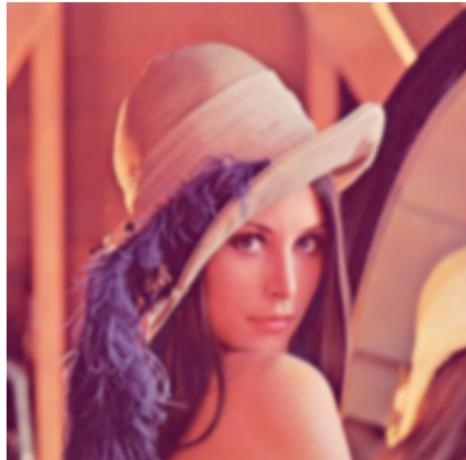


Figura: Convolução com kernel já rotacionado

# Pré-processamento de Imagens - Convolução



(a) Original



(b) Filtragem Gaussiana

# Pré-processamento de Imagens - Realce

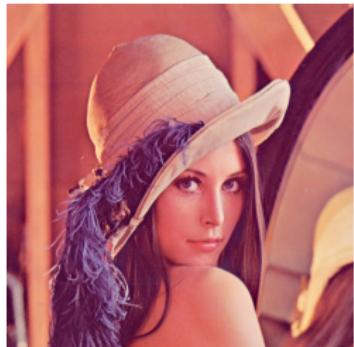


(a) Original



(b) *Unsharp masking*

# Pré-processamento de Imagens - Quantização



(a) Original

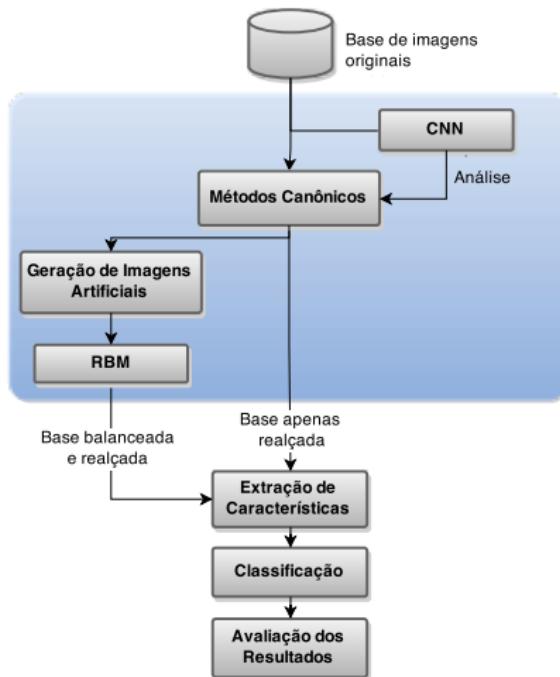


(b) Intensidade



(c) MSB

# Extração de Características



# Extração de Características

- ▶ Descrever as informações visuais relevantes em um vetor de características;
- ▶ Entrada para o classificador de padrões;
- ▶ Salientar as diferenças entre imagens de classes distintas e suavizar possíveis diferenças de imagens da mesma classe (Ex. algas - forma).

**Textura:** suavidade, aspereza e uniformidade. Ex. entropia;

**Forma:** características externas. Ex. curvatura;

**Cor:** distribuição espacial de cores na imagem. Ex. histograma.

# Extração de Características

**GCH** *Histograma global de cor - ND (intensidades).*

**CCV** *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

**BIC** *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

**ACC** *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância  $d$  um do outro. 1, 3, 5 e 7 - 4ND.

**Haralick** Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

# Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância  $d$  um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

# Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância  $d$  um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

# Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância  $d$  um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

# Extração de Características

GCH *Histograma global de cor - ND* (intensidades).

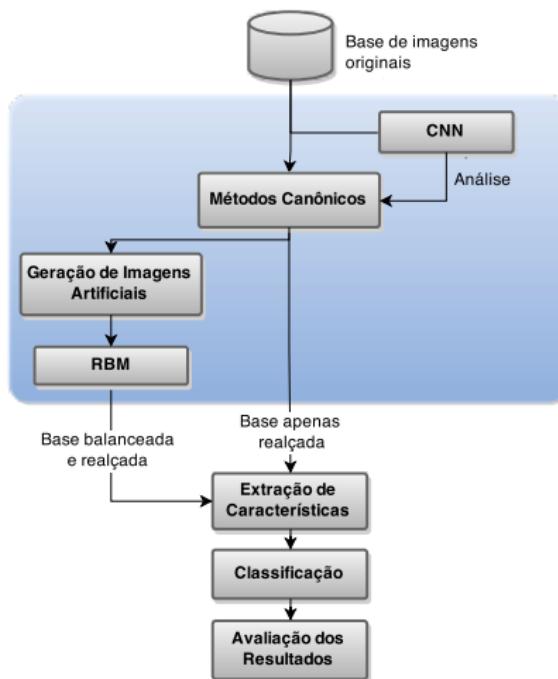
CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, computa e concatena os histogramas - 2ND.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Computa dois histogramas - 2ND.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância  $d$  um do outro. 1, 3, 5 e 7 - 4ND.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6D.

# Redes Neurais



# Redes Neurais

- ▶ Compreendem todo o pipeline;
- ▶ Aprendem as **características latentes** de imagens;
- ▶ Estado da arte da classificação, reconhecimento e localização de objetos;
- ▶ Imagens como treinamento para inferir as regras para a classificação;
- ▶ Conhecimento através da experiência: ao tentar uma solução e errar, aprendem e podem tentar novamente.
- ▶ Aprendizado: ajuste dos pesos entre a saída esperada e a produzida.

# Deep Learning

- ▶ Reconhecimento humano de novos padrões - capacidade de generalização (hierarquias);
- ▶ Simular o funcionamento do cérebro humano por meio de camadas;
- ▶ Redes neurais profundas possuem uma estrutura de muitas camadas – duas ou mais ocultas;
- ▶ Subdividem em problemas mais simples de serem resolvidos;
- ▶ Apesar de representarem o estado da arte em visão computacional, um bom entendimento das suas propriedades ainda está faltando.

# Redes Neurais

- ▶ Redes neurais de convolução (CNN - [?])
  - ▶ Camadas de neurônios para aprender as melhores características que diferenciam as classes;
  - ▶ Realçar essas características nas imagens;
- ▶ Máquinas de Boltzmann restritas (RBM)
  - ▶ Aprende a representação das imagens de entrada;
  - ▶ Definir quais imagens são relevantes para o aprendizado.

**Aprendem versões processadas das imagens de entrada: os filtros aprendidos são os que melhor diferenciam as classes.**

# Redes Neurais

- ▶ Redes neurais de convolução (CNN - [?])
  - ▶ Camadas de neurônios para aprender as melhores características que diferenciam as classes;
  - ▶ Realçar essas características nas imagens;
- ▶ Máquinas de Boltzmann restritas (RBM)
  - ▶ Aprende a representação das imagens de entrada;
  - ▶ Definir quais imagens são relevantes para o aprendizado.

**Aprendem versões processadas das imagens de entrada: os filtros aprendidos são os que melhor diferenciam as classes.**

# Redes Neurais

- ▶ Redes neurais de convolução (CNN - [?])
  - ▶ Camadas de neurônios para aprender as melhores características que diferenciam as classes;
  - ▶ Realçar essas características nas imagens;
- ▶ Máquinas de Boltzmann restritas (RBM)
  - ▶ Aprende a representação das imagens de entrada;
  - ▶ Definir quais imagens são relevantes para o aprendizado.

**Aprendem versões processadas das imagens de entrada: os filtros aprendidos são os que melhor diferenciam as classes.**

# Redes de Convolução

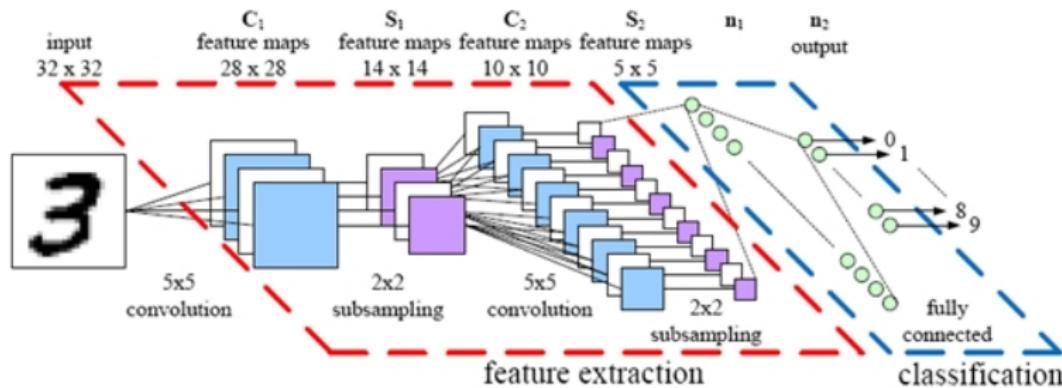


Figura: Arquitetura de uma CNN.

Fonte: <http://parse.ele.tue.nl/education/cluster2>

# Redes de Convolução

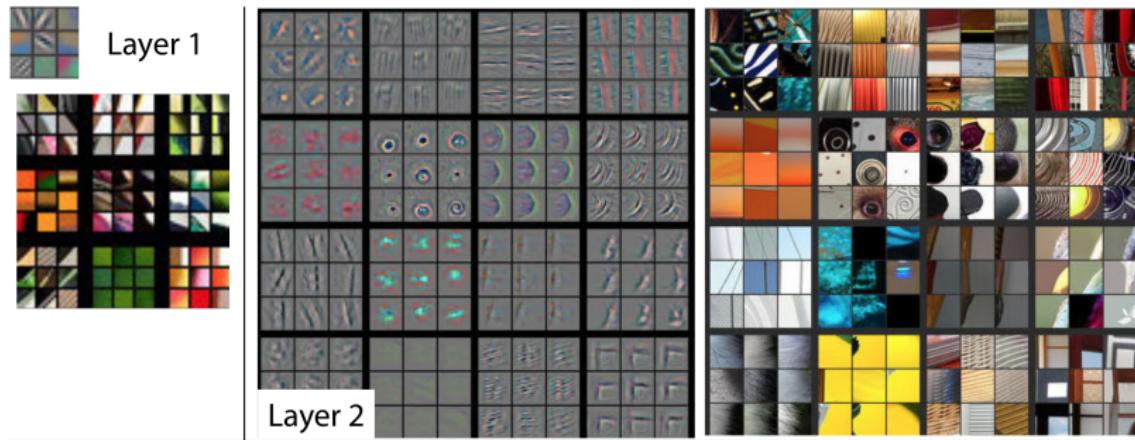


Figura: Primeira e segunda camada.

Fonte: [?]

# Redes de Convolução

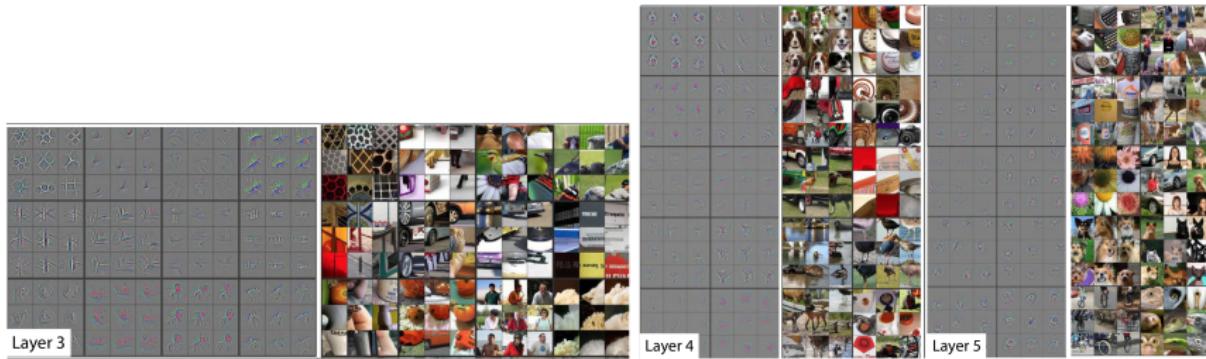
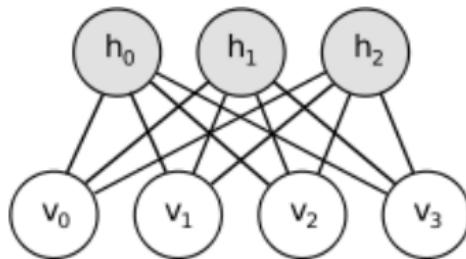


Figura: Terceira, quarta e quinta camada.

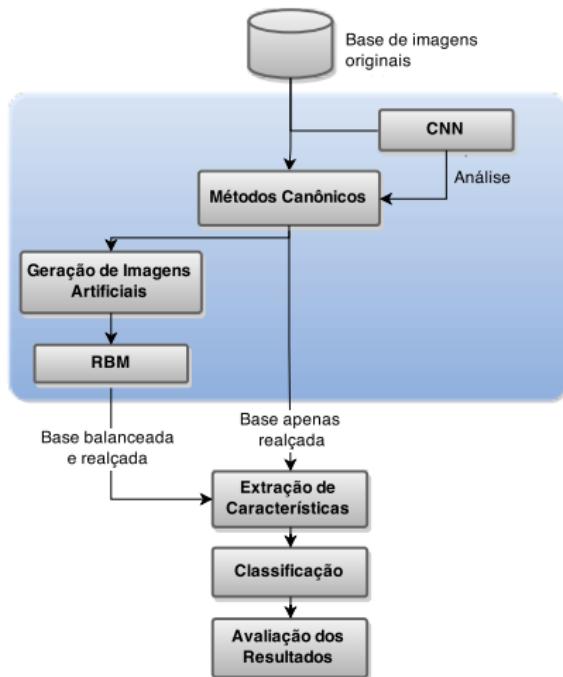
Fonte: [?]

# Máquina de Boltzmann restrita



- ▶ Rede neural estocástica que treina um modelo a partir dos vetores de entrada – memória associativa;
- ▶ Pixels: unidades visíveis. Detectores de características: unidades ocultas;
- ▶ Inicia em estado aleatório e atualiza os pesos até a distribuição estar em equilíbrio. Pode ser usada como entrada da CNN.;
- ▶ Mais simples, convenientes para a verificação da relevância de uma imagem para o aprendizado.

# Desbalanceamento de classes



# Desbalanceamento de classes

- ▶ Número desbalanceado de exemplos. Majoritárias x minoritárias.
- ▶ Abordagens
  - ▶ Pré-processamento dos dados: reamostrar os dados;
  - ▶ Modificar métodos de aprendizagem: adicionar funções de custo na classificação.

# Desbalanceamento de classes - Subamostragem

- ▶ Diminuir o número de elementos do conjunto;
- ▶ Podem remover informações essenciais dos dados originais;
- ▶ Eliminar elementos da classe majoritária distantes da fronteira de decisão;
- ▶ Normalmente apresentam resultados piores.

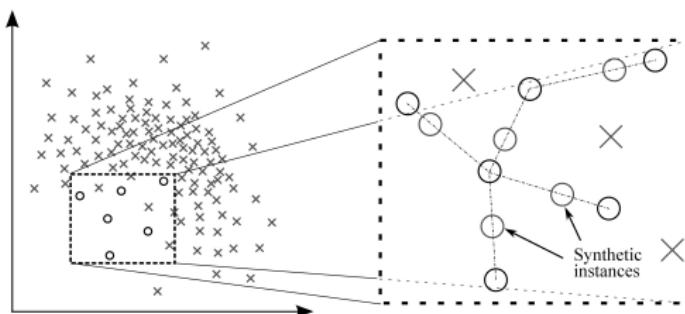
# Desbalanceamento de classes - Sobreamostragem

- ▶ Aumentar o número de elementos;
- ▶ Replicar não reporta melhorias;

## SMOTE

- ▶ Multiplica a diferença entre o vetor de características de um elemento e do seu vizinho mais próximo por um número [0-1];
- ▶ Adiciona ao vetor original, criando um novo elemento entre os dois vetores originais;
- ▶ Aprendida como exemplo da classe minoritária;
- ▶ Força uma região de decisão maior e mais geral;

# Desbalanceamento de classes - SMOTE



- ▶ Rebalancear ao gerar novos elementos, ao invés de replicá-los;
- ▶ Sobre os vetores de características previamente extraídos;
- ▶ (Chawla et al., 2002) **Diferentes estratégias para criar exemplos sintéticos podem melhorar a performance da classificação;**
- ▶ Utilizado para comparação.

# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

- Desbalanceamento de clas-  
ses

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Metodologia - Pesquisa Bibliográfica

- ▶ Características latentes;
- ▶ Redes neurais CNN e RBM;
- ▶ Desbalanceamento de classes;
- ▶ Descritores de características;
- ▶ Classificador de padrões.

# Metodologia - Implementação

- ▶ Biblioteca OpenCV;
- ▶ Linguagens de programação C++ e Python;
- ▶ Código disponível em [https://bitbucket.org/moacirponti/  
imagefeatureextraction/overview](https://bitbucket.org/moacirponti/imagefeatureextraction/overview).

# Metodologia - Bases de Imagens

- ▶ Viés genérico: diversas coleções de imagens com o objetivo de estabelecer ou refutar as hipóteses levantadas;
- ▶ Resultados preliminares com a base de imagens COREL<sup>a</sup>;

---

<sup>a</sup>Disponível em <http://wang.ist.psu.edu/docs/related/>



Figura: Base de imagens COREL-1000

# Metodologia - Bases de Imagens

## Bem discriminadas

- ▶ Cor: COREL-1000;
- ▶ Textura: Describable Textures Dataset<sup>a</sup> (DTD);
- ▶ Forma: Leafsnap<sup>b</sup>;

<sup>a</sup><http://www.robots.ox.ac.uk/~vgg/data/dtd/>

<sup>b</sup><http://leafsnap.com/dataset/>



Figura: DTD.



Figura: Leafsnap.

# Metodologia - Experimentos

- ▶ Explorar algoritmos de realce de características relevantes:
  - ▶ Melhorar discriminação entre as classes;
  - ▶ Cenários desbalanceados.
- ▶ Entrada: imagens originais das coleções disponíveis na literatura;
- ▶ Resultado: medidas estatísticas da classificação.

# Metodologia - Análise dos dados

- ▶ Comparar a classificação das imagens originais e as tratadas pelo método proposto;
- ▶ Comparar o método de rebalanceamento de classes com técnicas disponíveis na literatura, como o SMOTE.

# Metodologia - Avaliação

## Medida F1

Problema da acurácia: minoritária sem resultados corretos.

Performance da classificação em cenários desbalanceados.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{PR}{P + R}$$

# Metodologia - Avaliação

## Medida F1

Problema da acurácia: minoritária sem resultados corretos.

Performance da classificação em cenários desbalanceados.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{PR}{P + R}$$

# Metodologia - Avaliação

## Friedman

- ▶ Determinar se há diferença significante em uma amostra de resultados gerados;
- ▶ Analisa as performances dos algoritmos e atribui um *rank*;
- ▶ A hipótese nula a ser testada é que não há diferença estatística relevante entre as observações;
- ▶ P-valor indica a significância: quanto menor o seu valor, maior a evidência contra a hipótese nula (limiar de 0,05).

# Metodologia - Avaliação

## Mahalanobis

Distância entre a média e a variância das classes. Baseia na correlação entre as variáveis e pode ser definida por

$$D_m(x_i) = \sqrt{(x_i - \mu) C^{-1} (x_i - \mu)^T},$$

onde  $x_i$  é um vetor de valores,  $\mu$  a média e  $C$  a matriz de covariância.

# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

- Desbalanceamento de clas-  
ses

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Resultados Esperados

- ▶ Melhorar a classificação, validando-a com a medida-F1.
  - ▶ *Pré-processamento* de imagens que caracterizem melhor aspectos de suas classes, aumentando a variância entre as classes quando comparado com as imagens originais.
  - ▶ *Geração artificial de imagens* de classes minoritárias de forma a compensar o desbalanceamento natural das bases de dados.
- ▶ Analisar as características aprendidas com o treinamento de uma CNN com bases específicas;
- ▶ Escolher imagens que adicionam informações (RBM);
- ▶ Testar bases naturalmente não balanceadas.

# Descrição do Experimento



Figura: Geração de imagens artificiais para o rebalanceamento de classes por meio de: borramento, adição de ruído, mistura e combinação.

# Descrição do Experimento

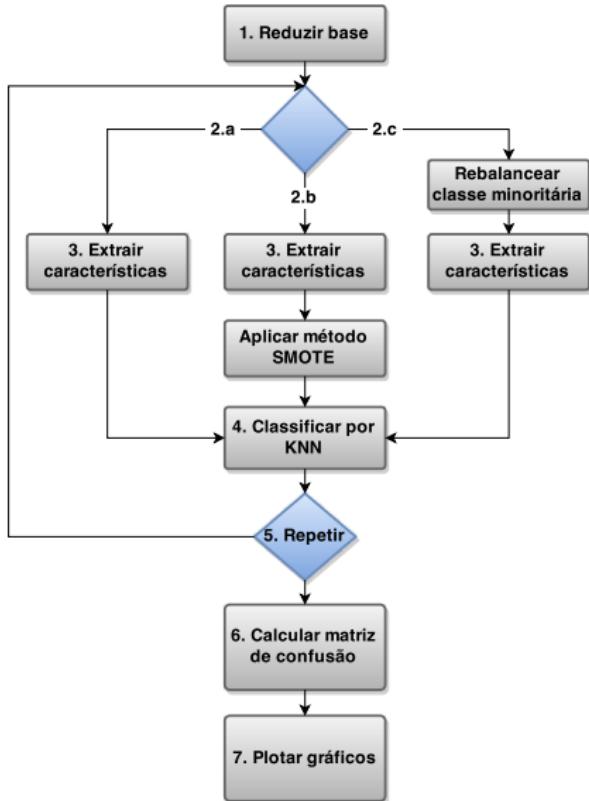


Figura: Fluxo dos resultados preliminares.

# Descrição do Experimento

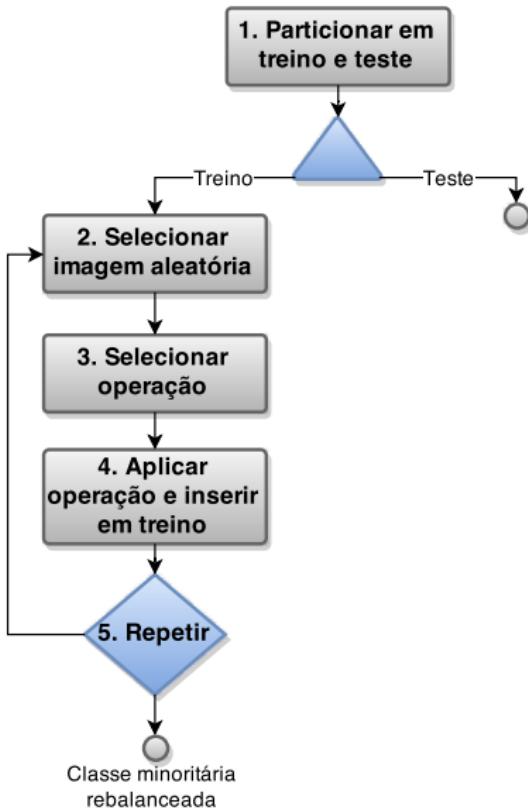


Figura: Fluxo da geração artificial.

# Resultados Preliminares

Classes com maior dificuldade de diferenciação, havendo alta taxa de sobreposição de intensidades de cores e texturas.



Figura: Classes “praia” e “montanha” da base de imagens COREL-1000.

# Resultados Preliminares - Melhor

- ▶ Ganho estatístico da medida-F, quando comparado à geração de exemplos artificiais no espaço de atributos;

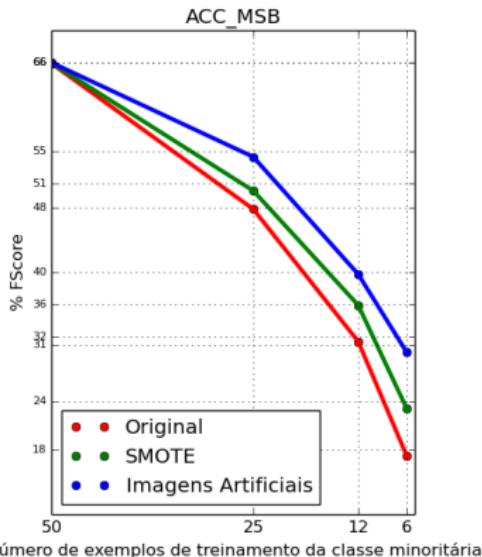


Figura: Resultado obtido com a operação de combinação.

# Resultados Preliminares - Pior

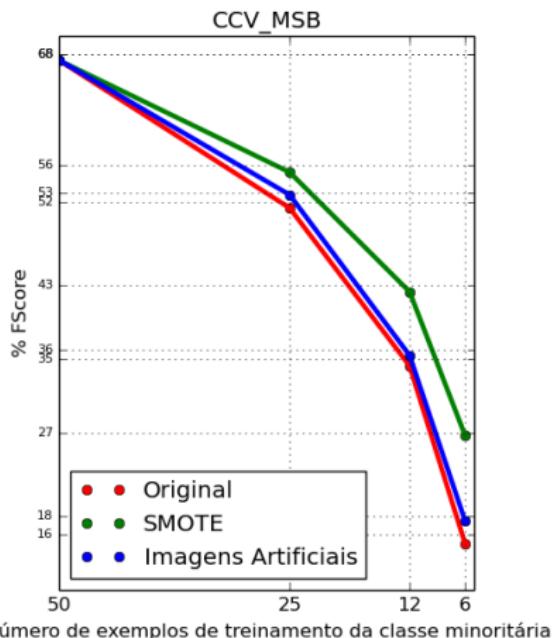


Figura: Piores resultados, obtidos com a adição de ruído.

# Resultados Preliminares

- ▶ Melhores operações: todas, apenas mistura e apenas composição;
- ▶ Piores: apenas borramento, ruído ou *unsharp masking* (filtros comuns);
- ▶ Melhor descritor: ACC;
- ▶ Piores: CCV e GCH;

# Resultados Preliminares

- ▶ Teste de Friedman para todas as execuções das melhores operações;
- ▶ P-valor =  $4.24E^{-11}$ ; Hipótese nula rejeitada.

Tabela: Posição média dos algoritmos utilizando Friedman

Algoritmos	Posição
Artificial	1.3863
Smote	1.6136
Original	3.0000

- ▶ Em algumas execuções: geração artificial (1), SMOTE (2) e imagens originais (3).

# Resultados Preliminares

- ▶ Replicação: SRS - *Simple Random Sampling*;
- ▶ Não adiciona informações novas para o aprendizado.

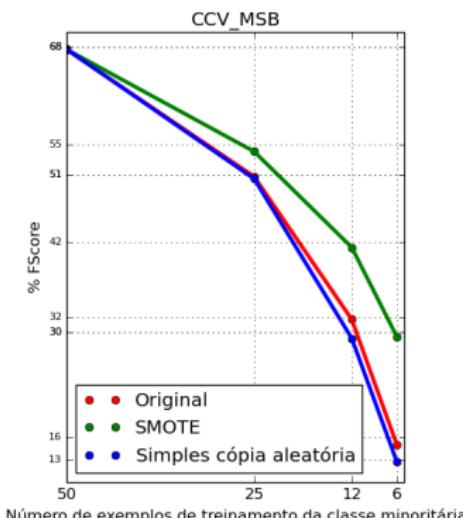


Figura: Simples replicação de exemplos sem pré-processamento.

# Resultados Preliminares - Rede de Convolução

<http://caffe.berkeleyvision.org/>

Tabela: Treinamento das classes praia e montanha da base COREL-1000.

Algoritmos	Medida F1
Original	0.708
Desbalanceada	0.577
Rebalanceada	0.677

# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

- Desbalanceamento de clas-  
ses

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

- Atividades e cronograma
- Referências

# Próximos Passos

- ▶ Desbalancear as 10 classes da COREL-1000 em escada;
- ▶ Utilizar todas as classes com apenas 1 desbalanceada;
- ▶ Analisar as características latentes que as redes neurais de convolução conseguem extrair
  - ▶ Bases bem discriminadas quanto às propriedades de textura, cor e forma.

# Próximos Passos

- ▶ Analisar a memória associativa de uma rede de Boltzmann
  - ▶ As imagens geradas foram adicionadas no conjunto de treino sem verificação da sua relevância;
  - ▶ Escolha para qual imagem original utilizar, ao invés do método aleatório utilizado nos resultados preliminares.

# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

- Desbalanceamento de clas-  
ses

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Atividades e Cronograma

Tabela: Duração de cada atividade a partir de 24/02/2014.

Atividade	2014		2015		2016
	1º Sem.	2º Sem.	1º Sem.	2º Sem.	1º Sem.
Disciplinas	[REDACTED]	[REDACTED]			
Revisão		[REDACTED]	[REDACTED]		
Geração artificial		[REDACTED]	[REDACTED]	[REDACTED]	
Características latentes			[REDACTED]	[REDACTED]	
Experimentos		[REDACTED]	[REDACTED]	[REDACTED]	
Escrita científica		[REDACTED]	[REDACTED]	[REDACTED]	[REDACTED]

# Artigo aceito na Neurocomputing

Image quantization as a dimensionality reduction procedure in color and texture feature extraction

Monair Ponti, Tiago S. Nazaré, Gabriela S. Thumé

*Instituto de Ciências Matemáticas e de Computação*

*Universidade de São Paulo*

*São Carlos, SP — Brazil — 13566-590*

---

## Abstract

The image-based visual recognition pipeline includes a step that converts color images into images with a single channel, obtaining a color-quantized image that can be processed by feature extraction methods. In this paper we explore this step in order to produce compact features that can be used in retrieval and classification systems. We show that different quantization methods produce very different results in terms of accuracy. While compared with more complex methods, this procedure allows the feature extraction in order to achieve a significant dimensionality reduction, while preserving or improving system accuracy. The results indicate that quantization simplify images before feature extraction and dimensionality reduction, producing more compact vectors and reducing system complexity.

**Keywords:** Image quantization, LPP, compact features extraction

---

*Email addresses:* ponti@usp.br (Monair Ponti), tiagoss@usp.br (Tiago S. Nazaré), gabithume@usp.br (Gabriela S. Thumé)

# Agradecimentos

Moacir Pereira Ponti Junior



*Conselho Nacional de Desenvolvimento  
Científico e Tecnológico*



# Estrutura da Apresentação

## 1 Introdução

- Motivação
- Hipóteses e Objetivos

## 2 Contextualização

- Pré-processamento
- Extração de características
- Redes de Convolução
- Máquina de Boltzmann res-  
trita

- Desbalanceamento de clas-  
ses

## 3 Metodologia

## 4 Resultados

- Resultados Esperados
- Descrição do experimento
- Resultados Preliminares

## 5 Próximos Passos

## 6 Atividades e cronograma

## 7 Referências

# Referências

# Geração de imagens artificiais e extração de características latentes aplicadas à classificação de imagens

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Pereira Ponti Junior

Instituto de Ciências Matemáticas e de Computação  
Universidade de São Paulo

27 de março de 2015

